

Grundzüge der Theoretischen Informatik

26.1.2022

Markus Bläser
Universität des Saarlandes

Noam Chomsky

Natürsprachliche Sätze strukturieren

< Subjekt > < Prädikat > < Objekt >

Kapitel 28: Grammatiken

Grammatiken

$(u, v) \in P$
"u kann durch v ersetzt werden"

Definition (28.1)

Eine Grammatik G ist ein 4-Tupel (V, Σ, P, S) :

1. V ist eine endliche Menge, die *Variablen* oder *Nichtterminale*.
2. Σ ist eine endliche Menge, die *Terminale*.
Es gilt $V \cap \Sigma = \emptyset$. / nichtleere Wörter
3. P ist eine endliche Teilmenge von $(V \cup \Sigma)^+ \times (V \cup \Sigma)^*$, die *Produktionen*.
4. $S \in V$ ist die *Startvariable*.

Kovention 28.2

Für $(u, v) \in P$ schreiben wir auch $u \rightarrow v$ statt (u, v) .

Ableitungen und erzeugte Sprache

$$abba \Rightarrow abbbab$$
$$(ba, bba) \in P$$

• kann in einem Schritt
abgeleitet werden

Definition (28.3)

1. Eine Grammatik $G = (V, \Sigma, P, S)$ definiert eine binäre Relation \Rightarrow_G auf $(V \cup \Sigma)^*$ wie folgt: $u \Rightarrow_G v$ falls wir $u = xyz$ und $v = xy'z$ schreiben können mit $y \rightarrow y' \in P$. Wir sagen v ist *ableitbar* aus u (in einem Schritt). v ist ableitbar aus u falls $u \Rightarrow_G^* v$.
 $u \Rightarrow u_1 \Rightarrow u_2 \Rightarrow \dots \Rightarrow v$
2. $u \in (V \cup \Sigma)^*$ heißt *Satzform*, falls $S \Rightarrow_G^* u$.
3. Eine Folge von Satzformen $w_0, \dots, w_t \in (V \cup \Sigma)^*$ mit $w_0 = S$, $w_\tau \Rightarrow_G w_{\tau+1}$ für $0 \leq \tau < t$ und $w_t = u$ heißt *Ableitung* von u .
4. Die von G erzeugte Sprache ist $L(G) = \{u \in \Sigma^* \mid S \Rightarrow_G^* u\}$.

Beispiel 28.4

Sei $G_1 = (\{S\}, \{0, 1\}, P_1, S)$ mit P_1 gegeben durch

$$S \rightarrow \varepsilon$$

$$S \rightarrow 0S1$$

$$\begin{array}{ccccccc} S & \Rightarrow & 0S1 & \Rightarrow & 00S11 & \Rightarrow & 000S111 & \dots \\ \downarrow & & \downarrow & & \downarrow & & \vdots & \\ \varepsilon & & 01 & & 0011 & & & \dots \end{array}$$

$$L(G_1) = \{0^n 1^n \mid n \in \mathbb{N}\}$$

Beispiel 28.6

$$v \rightarrow v_1, v \rightarrow v_2, v \rightarrow v_3 \dots$$

$$v \rightarrow v_1 | v_2 | v_3 | \dots$$

$$P_2 \subseteq (V \cup \Sigma)^+ \times (V \cup \Sigma)^*$$

Sei $G_2 = (\{W, V, N, N^+, Z, Z^+\}, \{a, b, \dots, z, 0, 1, \dots, 9, :, =, \neq, ;, +, -, [,]\}, P_2, W)$ mit P_2 gegeben durch

$$W \rightarrow V := V + V \mid V := V - V \mid V := N^+ \mid$$

$$\text{while } V \neq 0 \text{ do } W \text{ od } |$$

$$[W; W]$$

$$V \rightarrow x N^+$$

$$N^+ \rightarrow Z \mid Z^+ N$$

$$N \rightarrow Z \mid Z N$$

$$Z \rightarrow 0 \mid 1 \mid \dots \mid 9$$

$$Z^+ \rightarrow 1 \mid 2 \mid \dots \mid 9$$

~~N^+~~
 alle
 Ziffernfolgen
 ohne
 führende
 Nullen \Rightarrow

$$N \Rightarrow \begin{matrix} 0 \\ \vdots \\ 9 \end{matrix} N$$

Kodierung von N

Beispiel 28.7

$$L(G_3) = \{0^n 1^n 2^n \mid n \in \mathbb{N}\}$$

Sei $G_3 = (\{S, E, Z\}, \{0, 1, 2\}, P_3, S)$ mit P_3 gegeben durch

$$S \rightarrow 0EZ \mid 0SEZ$$

$$ZE \rightarrow EZ$$

$$0E \rightarrow 01$$

$$1E \rightarrow 11$$

$$1Z \rightarrow 12$$

$$2Z \rightarrow 22$$

$$\begin{array}{lcl}
 S & \Rightarrow & 0SEZ \Rightarrow 00SEZEZ \\
 \downarrow & & \Downarrow \\
 0EZ & & 00EZ EZ \\
 \downarrow & & \Downarrow \\
 01Z \Rightarrow 012 & & 001ZEZ \Rightarrow 0012EZ \quad \times \\
 & & \Downarrow \\
 & & 00112Z \Rightarrow 001122
 \end{array}$$

Die Chomsky-Hierarchie

$$U \rightarrow V_1$$

$$U \rightarrow V_2$$

$$\alpha \rightarrow AB$$

$$A \rightarrow \varepsilon$$

$$B \rightarrow \varepsilon$$

Definition (28.8)

Sei $G = (V, \Sigma, P, S)$ eine Grammatik.

1. Jede Grammatik G ist eine *Typ-0-Grammatik*.

$$\hat{=} RE$$

2. G ist eine *Typ-1-Grammatik*, falls $|u| \leq |v|$ für jedes $u \rightarrow v \in P$.

“nicht verkürzend”

$$\hat{=} NSPACE(n)$$

Die einzige Ausnahme ist $S \rightarrow \varepsilon$. Falls $S \rightarrow \varepsilon \in P$, dann erscheint S auf keiner rechten Seite.

3. G ist eine *Typ-2-Grammatik* falls sie Typ-1 ist und die linke Seite jeder Produktion aus V ist.

kontextfrei

4. G ist eine *Typ-3-Grammatik* falls sie Typ-2 ist und jede rechte Seite einer Produktion $\Sigma V \cup \Sigma$.

“rechtslinear”

$$\hat{=} REG$$

Die Chomsky-Hierarchie (2)

Definition (28.9)

Sei $i \in \{0, 1, 2, 3\}$. $L \subseteq \Sigma^*$ ist eine *Typ-i-Sprache*, falls es eine Typ-i-Grammatik G gibt mit $L = L(G)$.

Definition (28.10)

1. Die Menge aller Typ-2-Sprachen wird mit CFL bezeichnet.
2. Die Menge aller Typ-1-Sprachen wird mit CSL bezeichnet.

Theorem (28.12)

L ist eine Typ-3-Sprache genau dann, wenn L regulär ist.

Theorem (VI.6)

L ist eine Typ-0-Sprache genau dann, wenn $L \in \text{RE}$.

Beweis 28.12 Typ 3 \Rightarrow regulär, \Leftarrow Übung

Sei $G = (V, \Sigma, P, S)$ eine Typ 3-Grammatik für L .

Erst einmal nehmen wir an, dass $\epsilon \notin L$

Sei $F \notin V$

$\delta: Q \times \Sigma \rightarrow \mathcal{P}(Q)$

Sei $M = (V \cup \{F\}, \Sigma, \delta, S, \{F\})$

wobei δ definiert ist durch:

$$\delta(A, \sigma) = \begin{cases} \{B \mid A \rightarrow \sigma B\} & \text{falls } A \rightarrow \sigma \in P \\ \{B \mid A \rightarrow \sigma B\} \cup \{F\} & \text{sonst} \end{cases}$$

für alle $A \in V$ und $\sigma \in \Sigma$

Sei $w = v_1 v_2 \dots v_n \in \Sigma^*$

$$w \in L(G) \Leftrightarrow S \Rightarrow^* w$$

$\Leftrightarrow \exists$ Variablen $V_1, \dots, V_{n-1} \in V$ mit:

$$\begin{aligned} S &\Rightarrow v_1 V_1 \Rightarrow v_1 v_2 V_2 \Rightarrow \dots \quad / \quad V_1 \rightarrow v_2 V_2 \in P \\ &\dots \Rightarrow v_1 v_2 \dots v_{n-1} V_{n-1} \Rightarrow v_1 v_2 \dots v_n \quad / \quad V_{n-1} \rightarrow v_n \end{aligned}$$

$\Leftrightarrow \exists$ Zustände $V_1, \dots, V_{n-1} \in V$:

$$V_1 \in \delta(S, v_1), \quad V_2 \in \delta(V_1, v_2), \dots$$

$$V_{n-1} \in \delta(V_{n-2}, v_{n-1}), \quad \# \in \delta(V_{n-1}, v_n)$$

$\Leftrightarrow \exists$ akz. Berechnung von M auf w

$$\Leftrightarrow w \in L(M)$$

□

Kapitel 29: Kontextfreie Grammatiken

Ableitungsbäume und Mehrdeutigkeit

$$E \rightarrow E * E \mid E + E \mid (E) \mid x$$

Beispiel: $x + x * x$

Linksableitung:

$$E \Rightarrow E + E \Rightarrow x + E \Rightarrow x + E * E \Rightarrow x + x * E \Rightarrow x + x * x$$

The diagram illustrates the left derivation of the expression $x + x * x$. The sequence of steps is $E \Rightarrow E + E \Rightarrow x + E \Rightarrow x + E * E \Rightarrow x + x * E \Rightarrow x + x * x$. Colored arrows indicate the reductions: a green arrow from the first E to x in the second step; a blue arrow from the second E to $E * E$ in the third step; a red arrow from the third E to $x * E$ in the fourth step; and a magenta arrow from the fourth E to $x * x$ in the fifth step.

Rechtsableitung:

$$E \Rightarrow E + E \Rightarrow E + E * E \Rightarrow E + E * x \Rightarrow E + x * x \Rightarrow x + x * x$$

The diagram illustrates the right derivation of the expression $x + x * x$. The sequence of steps is $E \Rightarrow E + E \Rightarrow E + E * E \Rightarrow E + E * x \Rightarrow E + x * x \Rightarrow x + x * x$. Colored arrows indicate the reductions: a blue arrow from the second E to $E * E$ in the second step; a magenta arrow from the third E to $E * x$ in the third step; a red arrow from the fourth E to $x * x$ in the fourth step; and a green arrow from the first E to $x + x * x$ in the fifth step.

Ableitungsbäume





Definition (29.1)

Sei $G = (V, \Sigma, P, S)$ eine kontextfreie Grammatik.

1. Ein *Ableitungsbaum* ist ein geordneter Baum mit einer Knotenbeschriftung:
 - 1.1 Die Wurzel ist mit S beschriftet.
 - 1.2 Alle Blätter sind mit $V \cup \Sigma$ beschriftet oder mit ε . Im letzten Fall gibt es nur ein Blatt.
 - 1.3 Alle inneren Knoten sind mit Elementen aus V beschriftet. Falls A eine Knotenbeschriftung ist und x_1, x_2, \dots, x_t (in dieser Reihenfolge) die Beschriftungen der Kinder, dann ist $A \rightarrow x_1 x_2 \dots x_t \in P$.
2. Das *Blattwort* ist die Konkatenation der Beschriftungen der Blätter.

Beispiel

$x + x * x$



Eindeutigkeit

$$2+3=3+2$$

Definition (29.2)

1. Eine kfG heißt *mehrdeutig*, falls ein Wort zwei oder mehr Ableitungsbäumen hat. Sonst heißt sie *eindeutig*.
2. Eine kfS L heißt *eindeutig*, falls es eine eindeutige Grammatik für L gibt. Sonst ist Sie *inhärent mehrdeutig*.

$$S \rightarrow S_1 S_2$$

$$E \rightarrow T \mid T + E$$

$$T \rightarrow F \mid F * T$$

$$F \rightarrow x \mid (E)$$

$$S \rightarrow S_1 S_2$$

$$X + X * X$$



Theorem (29.3)

$\{0^n 1^n 2^m 3^m \mid n, m \geq 1\} \cup \{0^n 1^m 2^m 3^n \mid n, m \geq 1\}$ ist kontextfrei und inhärent mehrdeutig.